Clusterização de Perfis de Saúde da População Adulta Brasileira

Análise Não Supervisionada dos Dados VIGITEL 2024

FACOM32701 — Ciência de Dados II
Universidade Federal de Uberlândia

Camilly · Felype · Felipe Leme

Roteiro da Apresentação

01 **Contexto e Objetivos**
DCNT no Brasil e papel do VIGITEL 2024

02 **Dados e Pré-processamento**
Seleção de variáveis, limpeza e transformações

03 **Análise Exploratória**
Correlações, PCA e redução de dimensionalidade

04 **Metodologia**
K-Means, DBSCAN, Agglomerative + métricas de avaliação

05 **Resultados K=2**
Perfis: adultos jovens vs. idosos crônicos

06 **Resultados K=3**
Grupo oculto: jovens de risco comportamental

07 **Discussão e Limitações**
Interpretação dos achados e vieses dos dados

08 **Conclusões**
Implicações para políticas públicas de saúde

Contexto e Objetivos

74%

dos óbitos no Brasil
são por DCNT

O VIGITEL monitora anualmente fatores de risco e proteção para doenças crônicas em adultos das 26 capitais + DF, por inquérito telefônico.

Objetivos:

1. Identificar padrões alimentares e sua distribuição geográfica
2. Analisar clusters de hábitos por idade e escolaridade
3. Investigar associação depressão × hábitos × doenças físicas

Aprendizado não supervisionado permite descobrir subpopulações com perfis de risco distintos sem rótulos predefinidos — revelando padrões ocultos que análises descritivas tradicionais não capturam. Cada indivíduo é caracterizado por um vetor multidimensional de hábitos, condições crônicas e dados sociodemográficos.

Dados e Pré-processamento

Dataset VIGITEL 2024

900+ variáveis originais → 30 selecionadas

Domínios:
- Sociodemográficas (idade, sexo, escolaridade)
- Alimentação (feijão, frutas/verduras, ultraproc.)
- Atividade física e sedentarismo
- Tabagismo e álcool
- Antropometria (IMC)
- Saúde mental e doenças crônicas

Pipeline de Pré-processamento

1. Remoção de colunas vazias
2. Exclusão de variáveis redundantes
3. Imputação (depressão → 0 se ausente)
4. Conversão Sim/Não → 1/0
5. One-Hot Encoding (nominais)
6. Normalização Z-Score

Redução de Dimensionalidade — PCA

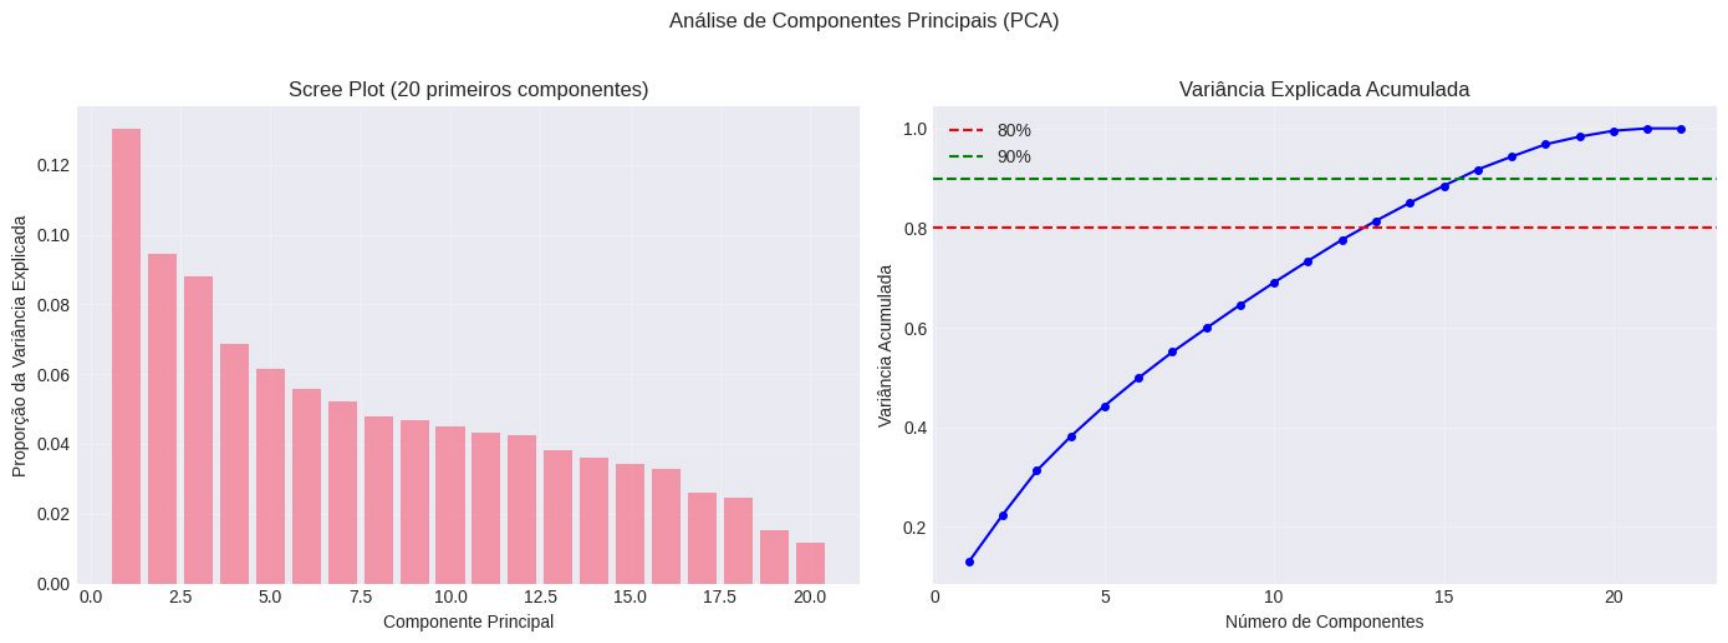

Scree Plot e Variância Explicada Acumulada — 95% retida para clusterização

A PCA reduziu a dimensionalidade mantendo 95% da informação, removendo ruído de variáveis one-hot e mitigando a maldição da dimensionalidade.

Metodologia

PCA

Redução de Dimensionalidade

Retenção de 95% da variância
t-SNE para visualização 2D

Clustering

3 Algoritmos Testados

K-Means (K=2..10)
Agglomerative (Ward)
DBSCAN

Avaliação

4 Métricas + Estabilidade

Silhouette, Davies-Bouldin
Calinski-Harabasz, Elbow
10 seeds, ARI > 0.95

Determinação do K Ótimo

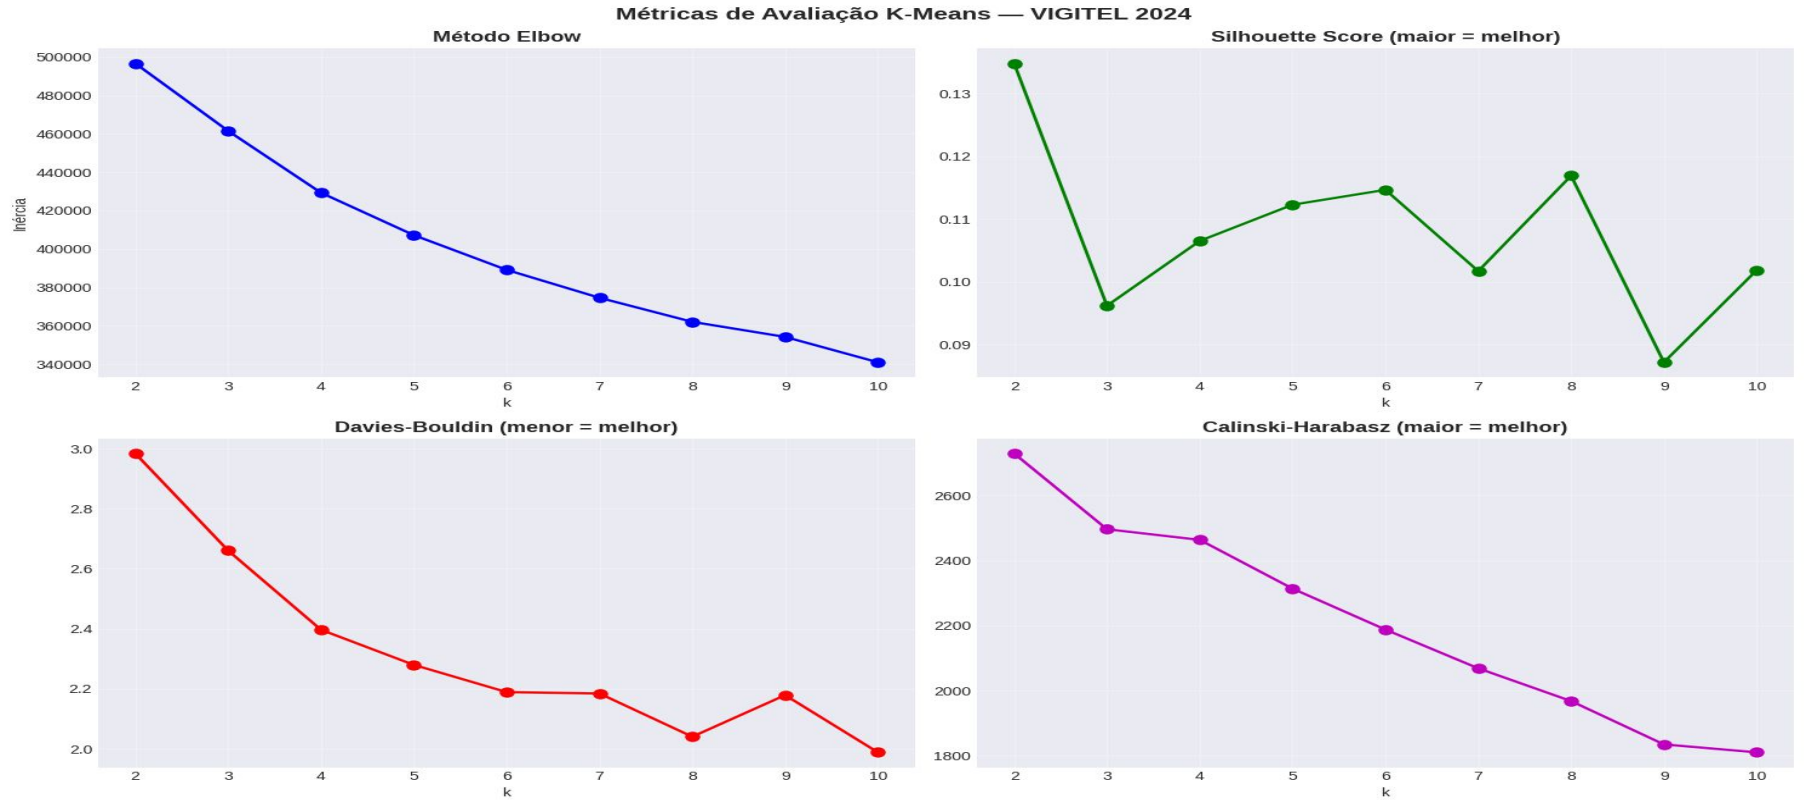

Elbow, Silhouette Score, Davies-Bouldin e Calinski-Harabasz — K ótimo = 2

Resultados — K=2 (Análise Principal)

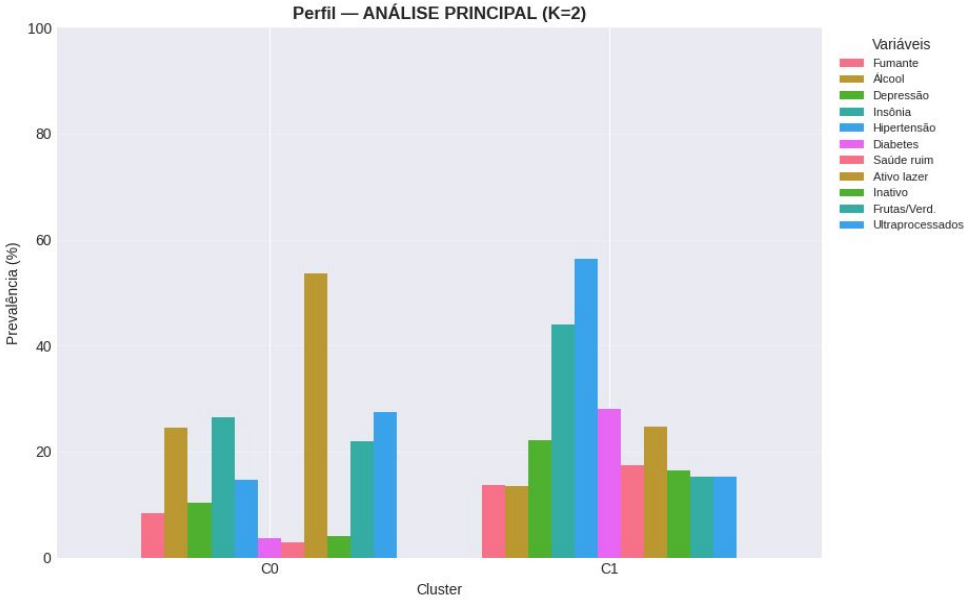

Perfil de prevalências e heatmap comparativo — Cluster 0 (jovens) vs. Cluster 1 (idosos)

C0: ~40 anos, escolaridade média, álcool 24,6%, ultraproc. 27,4%, ativo 53,7%

C1: ~56 anos, escolaridade baixa, hipertensão 56,3%, diabetes 28%, insônia 44%

K=2 — Radar de Risco e Distribuição de Idade

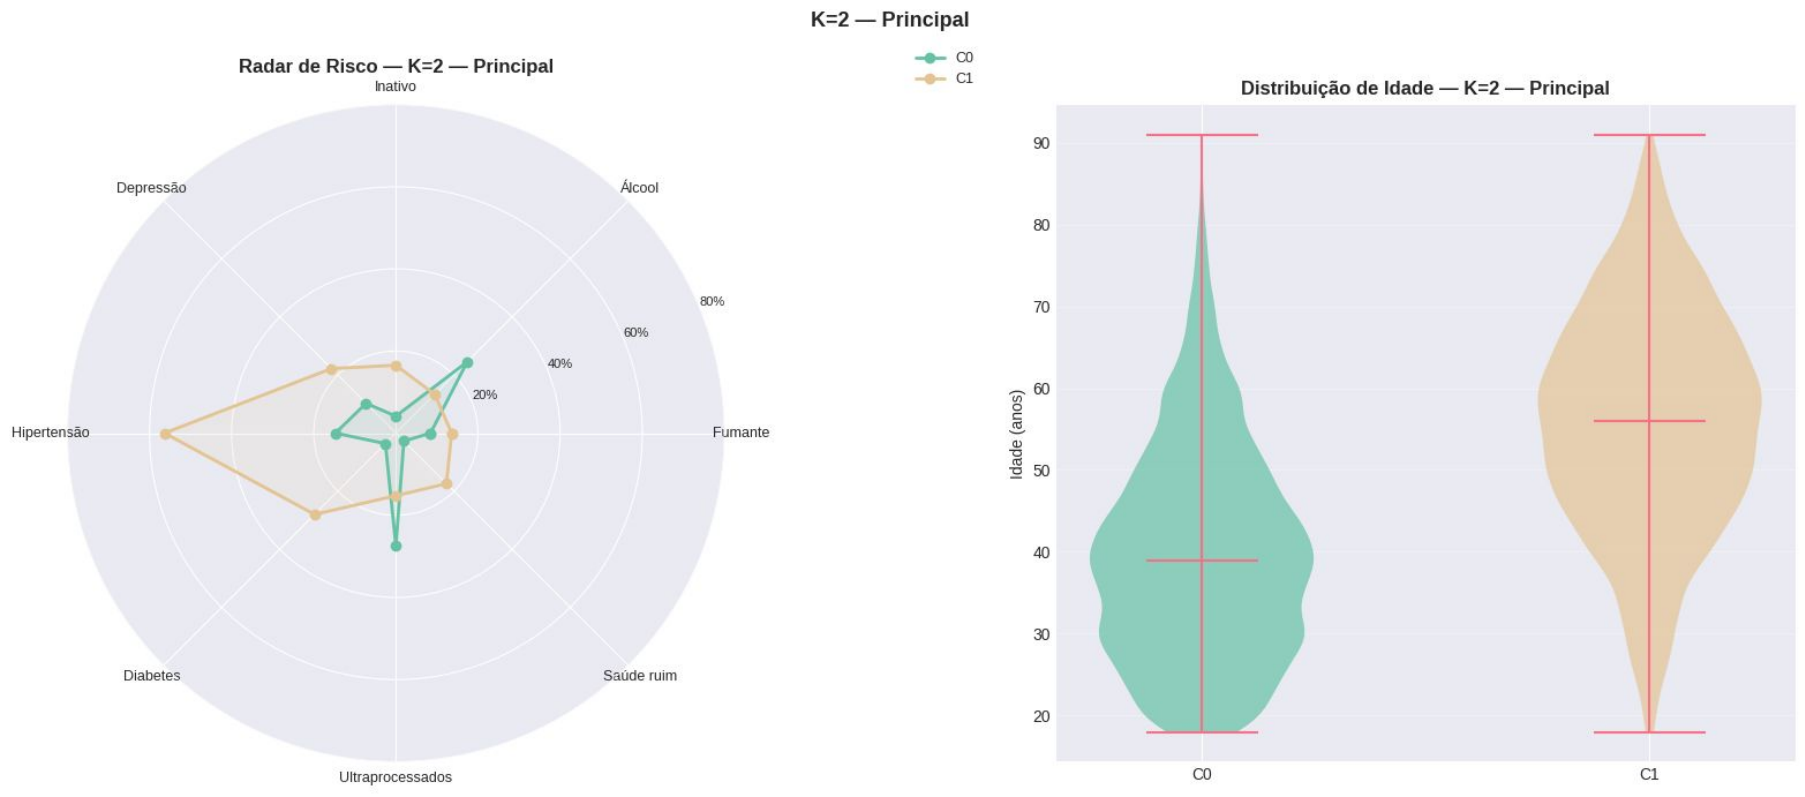

Radar de fatores de risco (esq.) e violin plot de idade por cluster (dir.)

Resultados — K=3 (Análise Complementar)

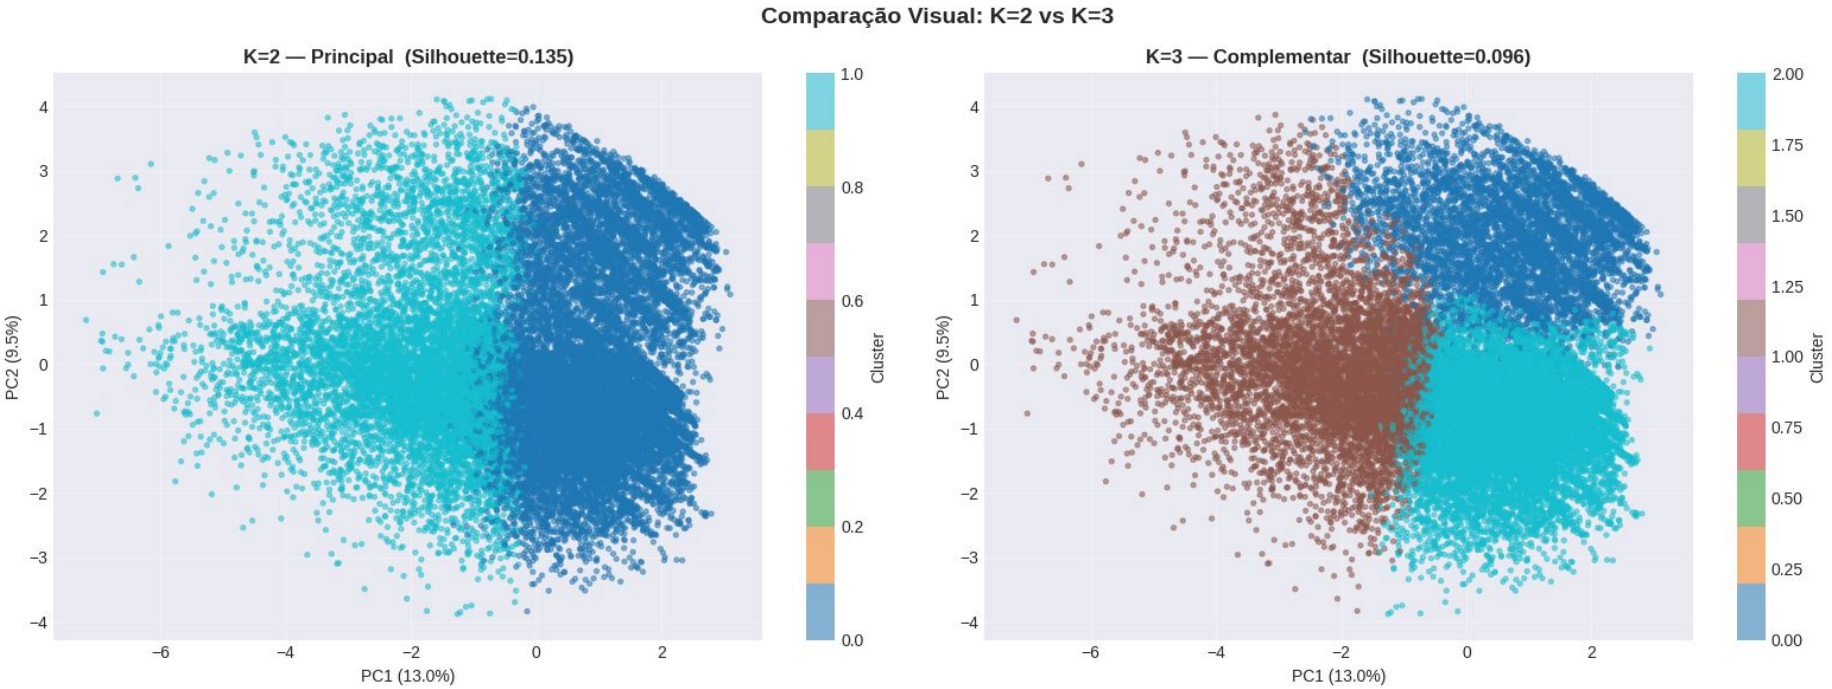

Comparação visual: dispersão PCA para K=2 (Silhouette=0.135) vs. K=3 (Silhouette=0.096)

K=3 revelou um grupo oculto: 50% da amostra com padrão alimentar e comportamental de alto risco antes dos 40 anos.

K=3 — Perfis dos Clusters

C0 (23%)

Meia-idade Saudável

Idade	~45 anos
Frutas/verd.	77%
Tabagismo	7%
Atividade	61%
Hipertensão	~10%

C1 (27%)

Idosos Crônicos

Idade	~56 anos
Frutas/verd.	~40%
Tabagismo	~15%
Atividade	~30%
Hipertensão	~55%

C2 (50%)

Jovens de Risco

Idade	~38 anos
Frutas/verd.	0%
Álcool	28%
Ultraproc.	33%
Hipertensão	14%

C2 é o principal alvo de intervenções preventivas: maior grupo (50%), pior padrão alimentar e comportamental, mas doenças crônicas ainda não consolidadas.

K=3 — Radar de Risco e Distribuição de Idade

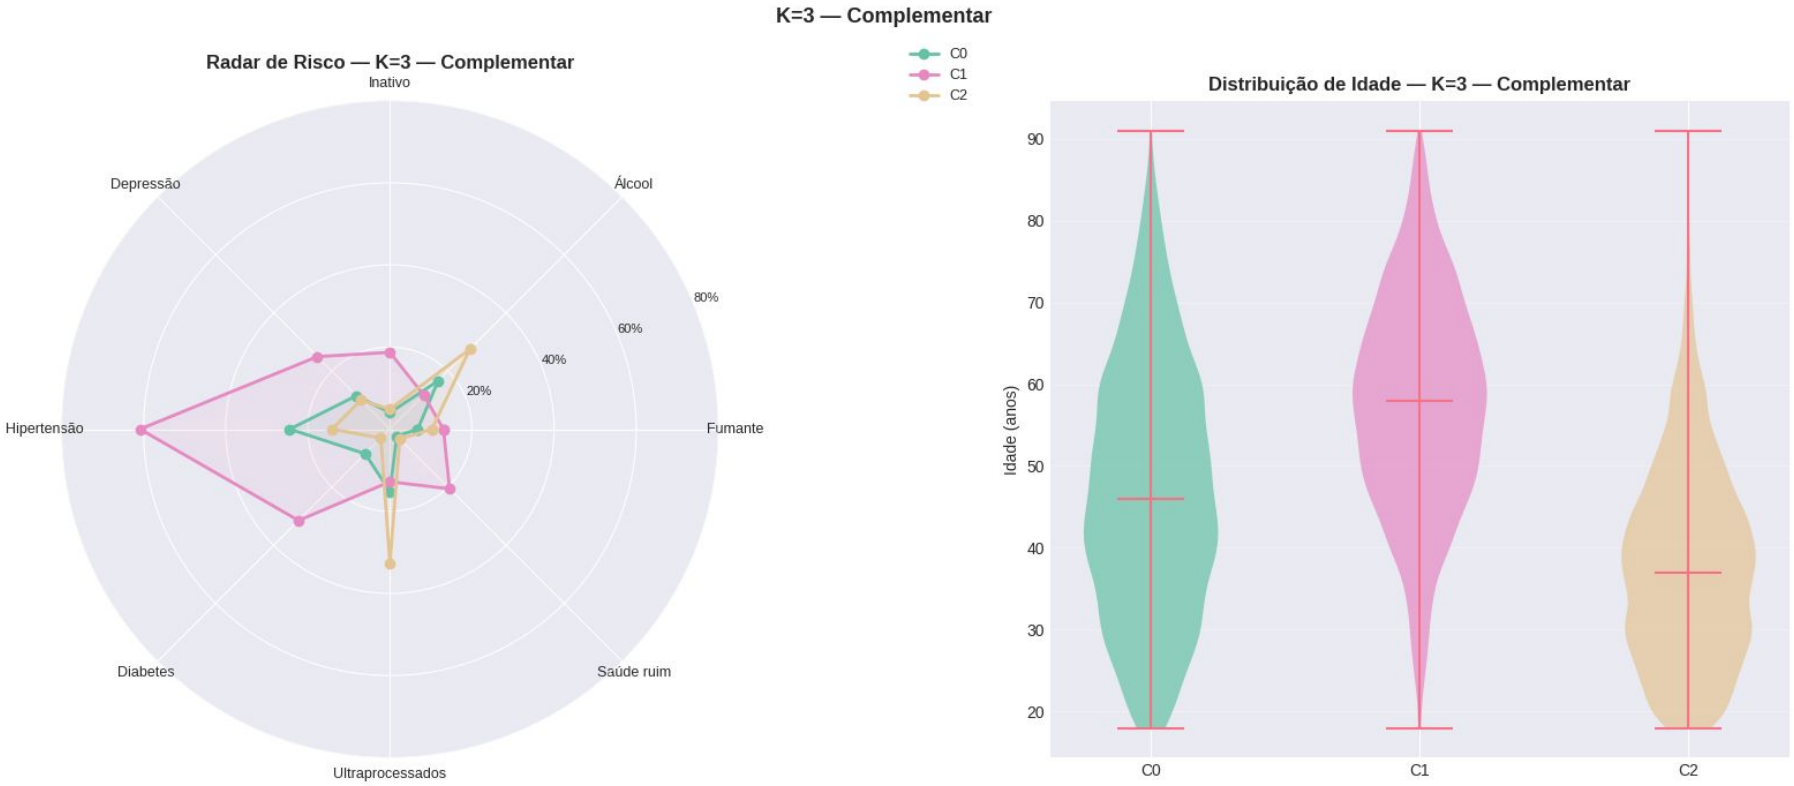

Radar de fatores de risco (esq.) e violin plot de idade por cluster (dir.) — K=3 Complementar

Discussão e Limitações

Principais Achados

- Separação geracional: jovens com risco comportamental vs. idosos com carga crônica
- K=3 revela grupo oculto (C2): 50% da amostra com pior padrão alimentar do dataset
- Escolaridade como fator estrutural — gerações mais velhas com menor literacia em saúde
- Sobrepeso universal (IMC ~27) em todos os clusters
- Depressão coexiste com múltiplas morbidades no cluster de idosos (22%)

Limitações

1. Viés de autorrelato por telefone
2. Apenas capitais com linha fixa
3. Corte transversal (sem causalidade)
4. Sem renda, raça ou acesso a saúde
5. K-Means + dist. euclidiana não ideal para variáveis mistas (usar K-Prototypes)

Conclusões — Implicações para Políticas Públicas

C1 — Idosos crônicos

Gestão de doenças instaladas: rastreamento, adesão medicamentosa, cuidado continuado na APS

C2 — Jovens de risco

Prevenção primária urgente: regulação de ultraprocessados, restrição de publicidade de álcool, promoção de saúde

C0 — Grupo saudável

Referência para replicação de comportamentos protetores na comunicação em saúde

Sobrepeso universal

Rotulagem frontal (RDC 429/2020), urbanismo saudável, educação alimentar nas escolas

Monitoramento

Aplicar clusterização no VIGITEL anual para acompanhar migração entre perfis de risco

Obrigado!

Clusterização de Perfis de Saúde — VIGITEL 2024
FACOM32701 — Ciência de Dados II — UFU

Camilly · Felype · Felipe Leme

Perguntas?