Trabalho Final de Ciência de Dados II - Agrupamento de Municípios pela Incidência de Doenças

Camilly de Melo Cruvinel,
Felipe Leme Dias,
Felype Henrique Hilário de Araújo

Universidade Federal de Uberlândia
Faculdade de Computação
Bacharelado em Sistemas de Informação

Uberlândia - MG
2026

Camilly de Melo Cruvinel,
Felipe Leme Dias,
Felype Henrique Hilário de Araújo

Trabalho Final de Ciência de Dados II - Agrupamento de Municípios pela Incidência de Doenças

Trabalho proposto na matéria de Ciência de Dados II, com foco em algoritmos não supervisionados, aplicados aos dados nacionais.

Área de concentração: Sistemas de Informação

Orientador: Marcelo Zanchetta

Uberlândia - MG
2026

Sumário

1 INTRODUÇÃO E OBJETIVO 3

2 DESCRIÇÃO DOS DADOS 5
2.1 Seleção de Variáveis 5
2.2 Pré-processamento 6

3 METODOLOGIA 7
3.1 Análise Exploratória (EDA) 7
3.2 Redução de Dimensionalidade — PCA 7
3.3 Algoritmos de Clusterização 8
3.4 Métricas de Avaliação 8
3.4.1 Teste de Estabilidade 8

4 RESULTADOS 9
4.1 Determinação do Número Ótimo de Clusters 9
4.2 Análise Principal — K=2 10
4.3 Análise Complementar — K=3 11
4.4 Painéis Visuais — Radar e Violin 12

5 DISCUSSÃO E CONCLUSÕES 13
5.1 Discussão 13
5.1.1 Limitações 13
5.2 Conclusões e Implicações para Políticas Públicas 14

REFERÊNCIAS 15

Capítulo 1

Introdução e Objetivo

Este relatório apresenta a aplicação de algoritmos de aprendizado não supervisionado sobre os microdados do VIGITEL 2024, o *Vigilância de Fatores de Risco e Proteção para Doenças Crônicas por Inquérito Telefônico*[1]; , com o objetivo de identificar perfis latentes de saúde na população adulta brasileira. A análise considerou múltiplas dimensões comportamentais e clínicas, incluindo hábitos alimentares, prática de atividade física, tabagismo, consumo de álcool, indicadores antropométricos e prevalência de doenças crônicas. Foram empregadas as técnicas K-Means, DBSCAN e Agglomerative Clustering, com validação baseada nos índices Silhouette Score, Davies-Bouldin e Calinski-Harabasz. Os resultados apontaram a existência de dois perfis principais (K=2) e um terceiro grupo caracterizado por comportamentos de risco (K=3), fornecendo subsídios relevantes para o aprimoramento de políticas públicas de prevenção em saúde.

Objetivo geral.

As doenças crônicas não transmissíveis (DCNT) constituem a principal causa de mortalidade no Brasil, correspondendo a cerca de 74% dos óbitos no país. Diante desse cenário, a identificação de subpopulações com perfis de risco heterogêneos torna-se estratégica para o planejamento e a execução de intervenções mais direcionadas e eficazes em saúde pública. Nesse contexto, o uso de métodos de aprendizado não supervisionado mostra-se particularmente promissor, por permitir a descoberta de agrupamentos naturais nos dados sem a necessidade de rótulos predefinidos, revelando padrões que frequentemente escapam às abordagens analíticas convencionais.

Objetivos específicos.

O presente estudo baseia-se nos dados do VIGITEL 2024, inquérito telefônico conduzido anualmente pelo Ministério da Saúde que monitora fatores de risco e proteção para DCNT em adultos residentes nas 26 capitais brasileiras e no Distrito Federal. Para

[1] <https://svs.aids.gov.br/daent/cgdnt/vigitel/>

atingir o objetivo proposto, foram definidas três perguntas norteadoras que orientaram as análises:

- Quais são os principais padrões alimentares da população adulta brasileira, e como se distribuem geograficamente?
- Como os clusters de hábitos saudáveis variam por idade e escolaridade?
- Como os clusters de hábitos saudáveis variam por idade e escolaridade?

A partir dessas questões, buscou-se não apenas caracterizar os agrupamentos identificados, mas também compreender suas relações com variáveis sociodemográficas e de saúde, ampliando o potencial de aplicação dos resultados em contextos de vigilância e intervenção em saúde pública.

Capítulo 2

Descrição dos dados

O dataset original do VIGITEL 2024 contém mais de 900 variáveis coletadas por inquérito telefônico. Foram identificados problemas comuns em dados de pesquisas populacionais: códigos especiais (777 para "Não sabe", 888 para "Não quis responder") misturados com valores numéricos reais, valores fora de faixa plausível (e.g., altura de 1.220 cm) e colunas inteiramente vazias devido à lógica de pulos do questionário.

Além do arquivo de dados, foi necessário baixar também o dicionário de variáveis disponibilizado no site do VIGITEL, uma vez que os nomes das colunas na base original não eram explícitos, dificultando a identificação do conteúdo de cada variável. O dicionário permitiu interpretar corretamente os códigos e compreender a estrutura do questionário.

2.1 Seleção de Variáveis

Foram selecionadas 30 variáveis essenciais organizadas em seis domínios temáticos:

- **Sociodemográficas:** idade, sexo, escolaridade (categórica e anos de estudo), cidade e região.
- **Alimentação:** consumo regular de feijão, frutas/verduras (regular e recomendado), refrigerante e ultraprocessados.
- **Atividade física:** atividade no lazer, em 3 domínios, inatividade física e tempo de TV (>3h/dia).
- **Tabagismo e álcool:** fumante atual, ex-fumante e consumo abusivo de álcool.
- **Antropometria:** IMC, excesso de peso e obesidade.
- **Saúde mental e crônicas:** depressão (diagnóstico e tratamento), insônia, hipertensão, diabetes, dislipidemia e autoavaliação de saúde ruim.

2.2 Pré-processamento

O pipeline de pré-processamento incluiu:

- remoção de colunas inteiramente vazias;
- exclusão de variáveis redundantes (faixa etária, obesidade e excesso de peso como derivações de idade e IMC);[•]
- imputação de zeros em "tratamento_depressão"para valores ausentes (interpretados como ausência de tratamento);
- remoção de linhas com valores ausentes nas demais variáveis críticas;
- conversão de variáveis binárias (Sim/Não para 1/0);
- One-Hot Encoding para variáveis categóricas nominais (sexo, cidade, região); e
- normalização Z-Score em todas as variáveis numéricas.

Capítulo 3

Metodologia

3.1 Análise Exploratória (EDA)

A análise exploratória incluiu estatísticas descritivas, histogramas e boxplots para todas as variáveis numéricas, além de uma matriz de correlação de Pearson para identificar redundâncias. Variáveis altamente correlacionadas foram sinalizadas para redução de dimensionalidade posterior.

3.2 Redução de Dimensionalidade — PCA

Aplicou-se PCA (Análise de Componentes Principais) retendo componentes suficientes para explicar 95% da variância total. A Figura 1 apresenta o scree plot e a curva de variância acumulada. A redução via PCA mitigou a maldição da dimensionalidade e removeu ruído das variáveis one-hot encoded. Adicionalmente, t-SNE foi aplicado sobre uma amostra de 5.000 pontos para visualização bidimensional.

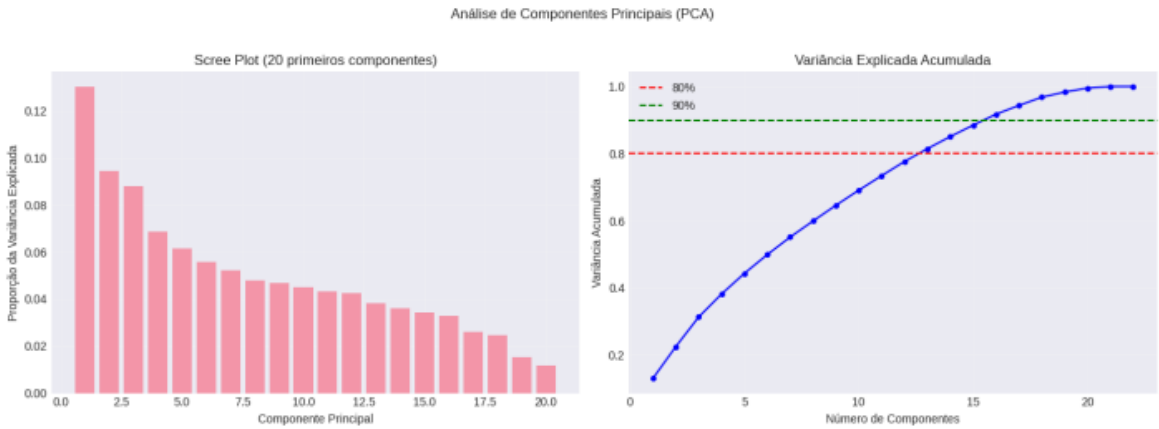

Figura 1 — Scree Plot PCA e Variância Explicada Acumulada

3.3 Algoritmos de Clusterização

Três algoritmos foram testados sobre os dados reduzidos por PCA:

- **K-Means:** com n_init=10 e busca de K ótimo entre 2 e 10.
- **Agglomerative Clustering:** com linkage Ward, para comparação hierárquica.
- **DBSCAN:** para detecção de clusters de forma arbitrária e outliers.

3.4 Métricas de Avaliação

A Tabela apresenta as métricas utilizadas para avaliação dos agrupamentos, juntamente com seus respectivos objetivos e valores de referência.

Métrica	Objetivo	Valor Ideal
Elbow (Inércia)	Ponto de inflexão na queda de inércia	Cotovelo visual
Silhouette Score	Coesão intra-cluster vs. separação inter-cluster	≥ 0.25
Davies-Bouldin	Razão dispersão/separação entre clusters	Menor possível
Calinski-Harabasz	Razão variância inter/intra-cluster	Maior possível

3.4.1 Teste de Estabilidade

O K-Means foi executado com 10 sementes diferentes (42, 123, 456, 789, 101, 202, 303, 404, 505, 606). A estabilidade foi medida por variância do Silhouette Score, Adjusted Rand Index (ARI) pareado e Normalized Mutual Information (NMI). Critério de referência: ARI > 0.8.

Capítulo 4

Resultados

4.1 Determinação do Número Ótimo de Clusters

A Figura apresenta as quatro métricas de avaliação para K de 2 a 10. O Silhouette Score, Calinski-Harabasz e Elbow apontaram K=2 como a separação mais nítida. O Davies-Bouldin, embora tenha valor mínimo em K=10, confirmou K=2 como a opção mais estável.

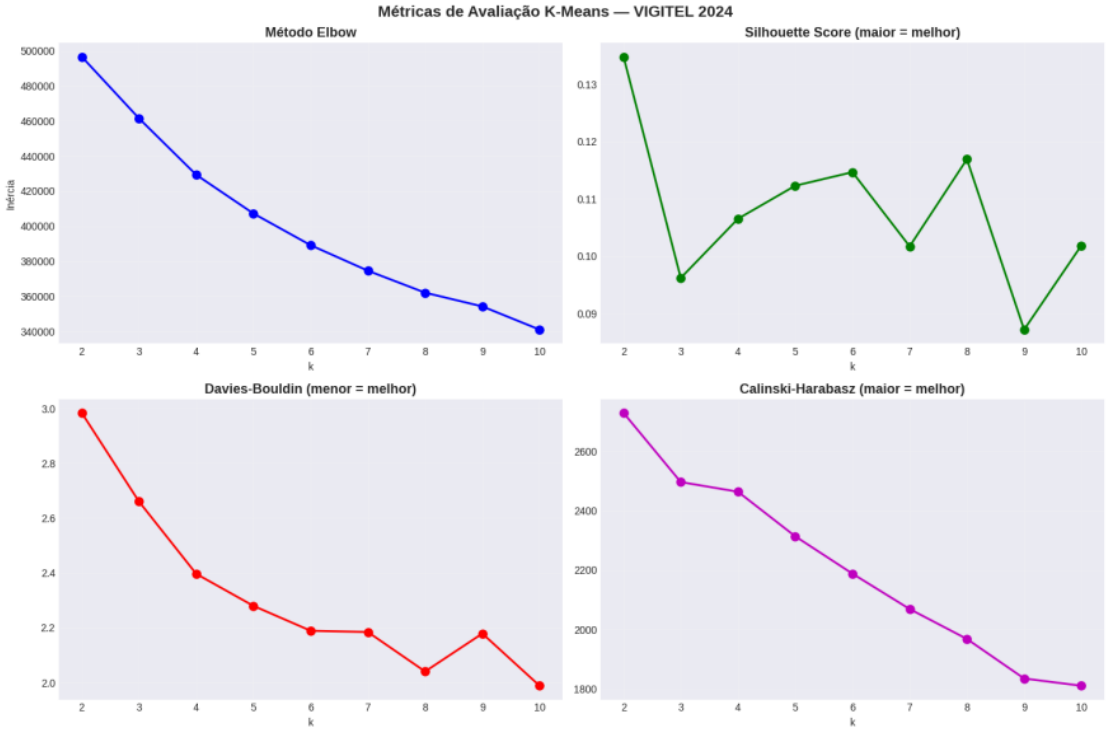

Figura 2 — Métricas de Avaliação: Elbow, Silhouette, Davies-Bouldin e Calinski-Harabasz

4.2 Análise Principal — K=2

A separação em dois grupos foi conduzida essencialmente por idade e acúmulo de doenças crônicas. A Figura a seguir apresenta o heatmap de prevalências e o perfil comparativo dos dois clusters.

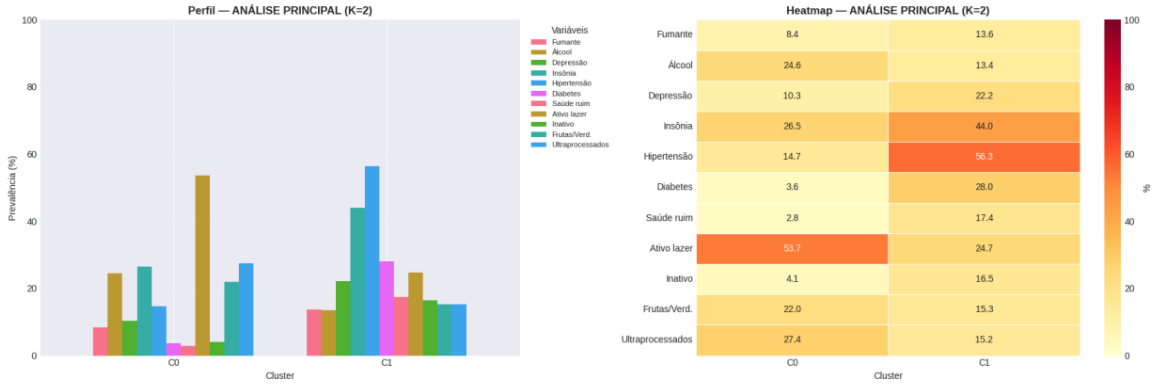

Figura 3 — Perfil e Heatmap de Prevalências — K=2

A Tabela a seguir apresenta as principais características de cada cluster identificado na solução com K=2.

Característica	Cluster 0 — Adultos Jovens	Cluster 1 — Idosos Crônicos
Idade média	~40 anos	~56 anos
Escolaridade	Média	Baixa
Hipertensão	14,7%	56,3%
Diabetes	3,6%	28,0%
Depressão	10,3%	22,2%
Insônia	26,5%	44,0%
Álcool abusivo	24,6%	13,4%
Ultraprocessados	27,4%	15,2%
Ativo no lazer	53,7%	24,7%

4.3 Análise Complementar — K=3

A análise com três clusters revelou um subgrupo oculto que K=2 não captava: adultos jovens (∼38 anos) com o pior padrão alimentar e comportamental do dataset. A Figura 4 compara a dispersão dos clusters no espaço PCA para K=2 e K=3.

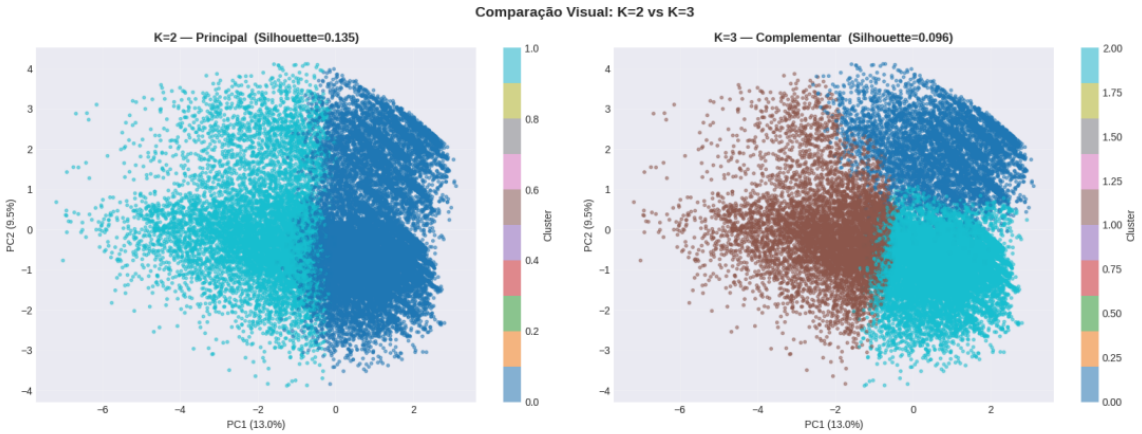

Figura 4 — Comparação Visual: Dispersão PCA para K=2 vs. K=3

A Tabela detalha as características dos três clusters identificados na solução com K=3.

Característica	**C0 (23%)** **Meia-idade Saudável**	**C1 (27%)** **Idosos Crônicos**	**C2 (50%)** **Jovens de Risco**
Idade média	∼45 anos	∼56 anos	∼38 anos
Frutas/verduras (rec.)	77%	∼40%	0%
Tabagismo	7%	∼15%	∼12%
Atividade física	61%	∼30%	∼45%
Hipertensão	∼10%	∼55%	14%
Álcool abusivo	∼15%	∼12%	28%
Ultraprocessados	∼12%	∼18%	33%

4.4 Painéis Visuais — Radar e Violin

As Figuras apresentam os gráficos radar de fatores de risco e os violin plots de distribuição de idade para K=2 e K=3, respectivamente.

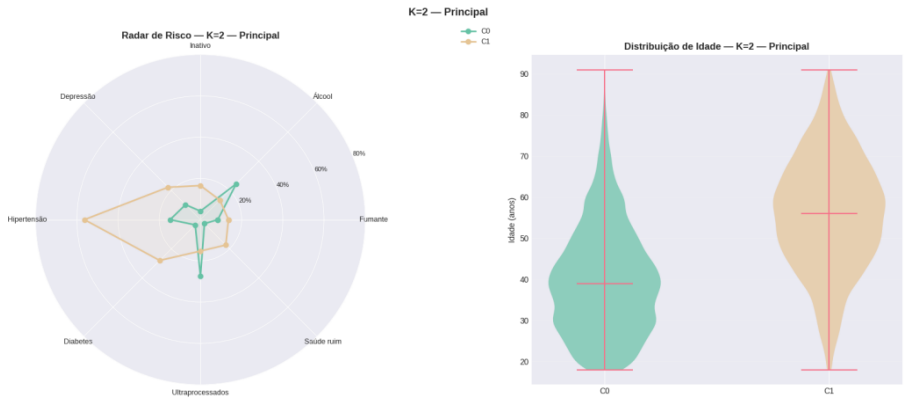

Figura 5 — Radar de Risco e Distribuição de Idade — K=2

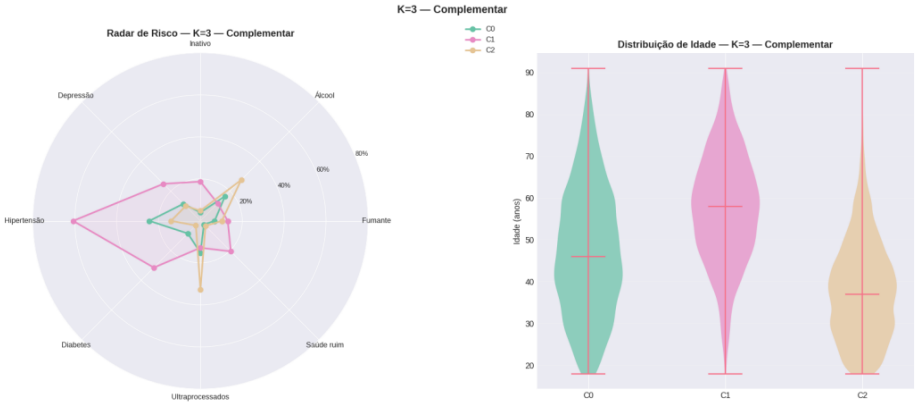

Figura 6 — Radar de Risco e Distribuição de Idade — K=3

Capítulo 5

Discussão e Conclusões

5.1 Discussão

O padrão mais marcante é a separação geracional: adultos jovens com comportamentos de risco (álcool abusivo, ultraprocessados) versus adultos maduros/idosos com alta carga de doenças crônicas já instaladas. A análise K=3 trouxe o achado mais relevante: o Cluster 2 (50% da amostra) composto por jovens (∼38 anos) com zero consumo recomendado de frutas e verduras, maior consumo de álcool (28%) e ultraprocessados (33%), com hipertensão já em 14%. Esse é o grupo com maior potencial de benefício de intervenções preventivas imediatas.

5.1.1 Limitações

- **Viés de autorrelato:** variáveis autorreferidas por telefone subestimam comportamentos negativos e superestimam positivos.
- **Cobertura amostral restrita:** apenas adultos de capitais com telefone fixo; populações rurais e de baixa renda estão sub-representadas.
- **Delineamento transversal:** corte único (2024), impossibilitando inferência causal ou análise longitudinal.
- **Variáveis ausentes:** renda domiciliar, raça/cor e acesso a serviços de saúde não foram incluídos.
- **K-Means para dados mistos:** a distância euclidiana não é ideal para variáveis binárias e contínuas combinadas. Alternativas como K-Prototypes e distância de Gower seriam mais adequadas.

5.2 Conclusões e Implicações para Políticas Públicas

- **Cluster de idosos crônicos (C1):** gestão de doenças já instaladas — rastreamento sistemático, adesão medicamentosa e cuidado continuado na Atenção Primária à Saúde.
- **Cluster de jovens de risco (C2, K=3):** prevenção primária urgente — regulamentação de ultraprocessados, restrição de publicidade de álcool e programas de promoção de saúde.
- **Cluster saudável (C0, K=3):** referência para estratégias de comunicação em saúde — replicação de comportamentos protetores.
- **Sobrepeso universal:** todos os clusters apresentaram IMC médio na faixa de sobrepeso ($\sim$27 kg/m^2), demandando rotulagem frontal (RDC 429/2020), urbanismo saudável e educação alimentar.
- **Monitoramento longitudinal:** aplicar esta clusterização nas edições anuais do VIGITEL permitiria acompanhar a migração entre perfis de risco.

Referências

BRASIL. Ministério da Saúde. **VIGITEL Brasil 2024: Vigilância de Fatores de Risco e Proteção para Doenças Crônicas por Inquérito Telefônico**. Brasília: MS, 2024. Nenhuma citação no texto.

PEDREGOSA, F. *et al.* Scikit-learn: Machine Learning in Python. **Journal of Machine Learning Research**, v. 12, p. 2825-2830, 2011. Nenhuma citação no texto.

ARTHUR, D.; VASSILVITSKII, S. K-means++: The Advantages of Careful Seeding. In: **Proceedings of the Eighteenth Annual ACM-SIAM Symposium on Discrete Algorithms** (SODA), 2007. Nenhuma citação no texto.

ROUSSEEUW, P. J. Silhouettes: A Graphical Aid to the Interpretation and Validation of Cluster Analysis. **Journal of Computational and Applied Mathematics**, v. 20, p. 53-65, 1987. Nenhuma citação no texto.

MALTA, D. C. *et al.* Doenças crônicas não transmissíveis e fatores de risco: principais achados do VIGITEL. **Ciência & Saúde Coletiva**, v. 26, n. 9, 2021. Nenhuma citação no texto.

Ferramentas: Python 3.x, pandas, scikit-learn, matplotlib, seaborn. Código disponível em repositório GitHub com README para reprodução.